Inteligência Artificial na Computação Forense: aplicações, desafios e explicabilidade na análise de evidências digitais

Iohanna Sofia Dietz Maldaner
Pontifícia Universidade Católica do Rio Grande do Sul
Porto Alegre, Rio Grande do Sul, Brasil
[redacted]

Abstract

A computação forense enfrenta o desafio de analisar volumes cada vez maiores e mais diversos de evidências digitais, o que tem motivado a aplicação de técnicas de inteligência artificial (IA) na área. Este artigo tem como objetivo analisar como a IA vem sendo aplicada à computação forense e quais desafios precisam ser enfrentados para que seus resultados sejam confiáveis e compreensíveis. Para isso, foi realizada uma pesquisa bibliográfica exploratória no Google Scholar, que resultou na seleção de três estudos publicados entre 2021 e 2024. A análise comparativa mostrou que a IA é aplicada principalmente nas fases de triagem, exame e análise, trazendo benefícios como a redução do tempo de investigação e o processamento de grandes volumes de dados. Por outro lado, a confiabilidade dos resultados ainda é limitada por problemas de qualidade dos dados, generalização, falsos positivos e negativos e falta de validação em casos reais. A explicabilidade (XAI) surge como uma proposta para tornar os resultados compreensíveis, especialmente em tribunais, mas sua admissibilidade ainda não pode ser determinada. Conclui-se que a IA deve ser vista como uma ferramenta de apoio ao especialista humano, e não como sua substituta.

Palavras-chave

Inteligência artificial, Computação forense, Evidências digitais, Aprendizado de máquina, Explicabilidade

1 Introdução

A computação forense abrange a aquisição, o processamento e a análise de grandes quantidades de dados digitais com o propósito de apoiar investigações criminais [Artigo 2]. Tanner e Dampier (2009 apud [Artigo 1]) descrevem esse trabalho em fases, conforme o modelo do Digital Forensics Research Workshop (DFRWS), descrito por eles: tradicionalmente, esse trabalho é organizado nas fases de identificação, preservação, coleta, exame, análise e apresentação. Esse processo, no entanto, tem sido pressionado pelo crescimento do volume e da diversidade das evidências, pela variedade de dispositivos e pelo uso de técnicas como criptografia e antiforense [Artigo 1], [Artigo 2], além do alto custo das análises conduzidas manualmente [Artigo 1].

Nesse âmbito, portanto, técnicas de IA, em especial o aprendizado de máquina (*machine learning*) e o aprendizado profundo (*deep learning*), passaram a ser propostas a fim de automatizar etapas investigativas, identificar padrões e anomalias em grandes conjuntos de dados e reduzir o tempo de análise [Artigo 1], [Artigo 2]. A adoção dessas técnicas, entretanto, acaba levantando questões que vão além da eficiência: a qualidade e a validação dos dados usados, a confiabilidade dos resultados produzidos e a possibilidade de explicá-los, especialmente quando a evidência precisa ser apresentada em processos judiciais [Artigo 2], [Artigo 3].

De acordo com o relatório "2021 Annual Data Breach Report Sets New Record for Number of Compromises", do Identity Theft Resource Center (ITRC, 2022 apud [Artigo 2]), os ataques cibernéticos aumentaram em 68% em comparação ao ano anterior. Nesse cenário, percebe-se a necessidade de medidas que auxiliem e acelerem o processo investigativo. Nesse âmbito, em computação forense, IA e ML se provam particularmente úteis [Artigo 2], uma vez que alguns algoritmos de IA e ML são capazes de detectar padrões e irregularidades que podem não ser imediatamente aparentes ao olho humano, sendo vantajosos para identificar evidências escondidas e ocasionando resultados mais confiáveis e acurados.

Para obter-se um entendimento mais amplo de como a IA apareceu como uma potencial solução para os desafios da computação forense, é imperativo o entendimento do que são o aprendizado de máquina (*machine learning* – ML) e o aprendizado profundo (*deep learning* – DL). Segundo Jarrett e Choo [Artigo 1], ML é a maneira como um sistema computacional ou algoritmo consegue consumir altos volumes de dados e, enfim, fazer previsões ou chegar a conclusões (Choy et al., 2018 apud [Artigo 1]). O aprendizado de máquina usa modelos regressivos e classificações para fazer previsões sobre os dados que o aprendizado de máquina está analisando (Xin et al., 2018 apud [Artigo 1]). Quando o ML é aplicado a tarefas simples, ele performa bem, mas, quando um volume maior de dados é adicionado para análise, a complexidade do aprendizado cresce exponencialmente (Arel, Rose e Karnowski, 2010 apud [Artigo 1]). Tendo este cenário em mente, foi criado o aprendizado profundo (*deep learning*). O *deep learning* é um ramo especializado da tecnologia de *machine learning*, que resolve dados complexos (Arel et al., 2010 apud [Artigo 1]) usando redes neurais (*neural networks*): um algoritmo de ML padrão com dados complexos, por vezes, necessita de um desenvolvedor humano para corrigir o aprendizado incorreto, já os algoritmos de DL fazem essa correção por si só, validando o que foi aprendido [Artigo 1].

Cabitza et al. (2023 apud [Artigo 2]) afirmam que, apesar do progresso considerável feito com IA e ML, ainda existem múltiplos desafios nesse ramo, como a incompatibilidade de aplicações existentes. A qualidade e a integridade dos dados podem ser comprometidas durante a coleta e a análise de dados, resultando em resultados errôneos e inconfiáveis [Artigo 2]. Nesse mesmo cenário, com a introdução de IA em forense digital, deve-se ter em mente o risco associado ao *machine learning* em que os modelos de IA são treinados usando dados comprometidos ou parciais, tornando difícil saber se os modelos usados em investigações são confiáveis

[Artigo 3]. Nesse contexto, a admissibilidade de evidências coletadas pela IA em tribunais depende da sua confiabilidade [Artigo 2]. Nesse sentido, em tribunais, é necessário que decisões feitas por ferramentas de inteligência artificial, ou com a ajuda delas, possam ser justificadas e explicadas a um humano [Artigo 3]. Assim, para que as técnicas que utilizam IA atinjam seu máximo potencial no ramo de computação forense, é preciso abordar a escalabilidade e as preocupações com a validação da evidência [Artigo 2]. Dessa forma, a explicabilidade (XAI) entra como uma potencial solução, que aborda o problema da "caixa-preta", em que algoritmos de *machine learning* muitas vezes tomam decisões através de métodos que não podem ser explicados em suas especificidades [Artigo 3], o que faria com que a integração da XAI mudasse a forma como a evidência digital é apresentada em procedimentos legais, mudando também o papel do especialista humano.

Diante desse cenário, este artigo tem como objetivo analisar, por meio de uma pesquisa bibliográfica de caráter exploratório, como técnicas de inteligência artificial vêm sendo aplicadas à computação forense, identificando seus principais benefícios, limitações e desafios relacionados à confiabilidade e à explicabilidade dos resultados na análise de evidências digitais. Para isso, busca-se responder à seguinte questão de pesquisa: *como a inteligência artificial vem sendo aplicada à computação forense e quais desafios precisam ser enfrentados para que seus resultados sejam confiáveis e compreensíveis?* O restante do artigo está organizado da seguinte forma: a Seção 2 descreve o procedimento de busca e seleção dos estudos; a Seção 3 apresenta a análise e a síntese comparativa dos três estudos selecionados, abordando as aplicações da IA, seus benefícios, os limites da confiabilidade, a contribuição da explicabilidade, o papel do especialista humano e as lacunas identificadas; por fim, a Seção 4 apresenta as conclusões da pesquisa.

2 Metodologia de Pesquisa

2.1 Tipo de pesquisa

Este trabalho caracteriza-se como uma pesquisa bibliográfica de caráter exploratório, realizada com o objetivo de identificar e analisar estudos relacionados à aplicação da inteligência artificial na computação forense. A pesquisa foi feita a partir do levantamento de trabalhos científicos disponíveis na literatura, buscando compreender as principais aplicações da inteligência artificial, seus benefícios, limitações, questões relacionadas à confiabilidade dos resultados e o uso de técnicas de explicabilidade.

2.2 Procedimento de busca e critérios de seleção

A busca dos estudos foi realizada por meio do Google Scholar, utilizando diferentes combinações de palavras-chave relacionadas ao tema da pesquisa. O procedimento de busca foi dividido em quatro estratégias, com o objetivo de contemplar tanto a aplicação geral da inteligência artificial na computação forense quanto aspectos específicos relacionados ao aprendizado de máquina (*machine learning*), à confiabilidade dos resultados e à explicabilidade (XAI).

As palavras-chave utilizadas foram:

- *"artificial intelligence" "digital forensics"*;
- *"machine learning" "digital forensics"*;
- *"artificial intelligence" "digital forensics" "reliability"*;
- *"explainable AI" "digital forensics"*.

A seleção dos estudos considerou principalmente a relação direta com o tema da pesquisa e a data de publicação. Como a inteligência artificial é uma área em constante evolução, foi priorizada a seleção de estudos publicados a partir de 2021, com preferência pelo idioma inglês e que tivessem foco direto em IA aplicada à forense digital, buscando contemplar discussões mais atuais sobre a utilização dessas técnicas na computação forense. Também foi levada em conta a complementaridade entre os estudos ao fazer a triagem por título e resumo. A partir dos resultados obtidos nas buscas, foram selecionados três estudos para análise.

2.3 Caracterização dos estudos selecionados

Os três estudos selecionados apresentam diferentes perspectivas sobre a utilização da inteligência artificial na computação forense. Enquanto os trabalhos analisam aplicações e benefícios da IA e do aprendizado de máquina, também são abordadas limitações relacionadas à confiabilidade dos resultados e à necessidade de explicabilidade. A caracterização dos estudos selecionados é apresentada na Tabela 1.

Tabela 1: Caracterização dos estudos selecionados

Estudo	Ano	Tipo	Foco
[Artigo 1] Jarrett e Choo	2021	Revisão de literatura	Automação e IA
[Artigo 2] Dunsin et al.	2024	Revisão de literatura descrita como sistemática	IA/ML em forense digital e resposta a incidentes
[Artigo 3] Hall, Sakzad e Choo	2022	Artigo de opinião com proposta de modelo teórico	XAI

O artigo "The impact of automation and artificial intelligence on digital forensics", dos autores Aaron Jarrett e Kim-Kwang Raymond Choo [Artigo 1], aborda um panorama das aplicações e dos impactos gerados por sistemas de IA; já o artigo "A comprehensive analysis of the role of artificial intelligence and machine learning in modern digital forensics and incident response" [Artigo 2] é dedicado a explorar a integração de técnicas de IA e *machine learning* no contexto de forense digital e resposta a incidentes, fazendo uma revisão crítica dos modelos e de suas limitações. Nesse contexto, no artigo "Explainable Artificial Intelligence for Digital Forensics" [Artigo 3], há uma abordagem diferente da dos outros dois, ao fazer uma proposta sobre explicabilidade (XAI), explicando seu potencial na área de computação forense.

2.4 Limitações na seleção de artigos

O número reduzido de estudos, o uso de uma única base e o idioma único restringem a generalização dos resultados.

3 Análise e Síntese dos Dados Encontrados

Esta seção apresenta a análise comparativa dos três estudos selecionados. Em vez de descrever cada trabalho separadamente, a discussão foi organizada em eixos temáticos, de modo a evidenciar convergências, divergências e complementaridades entre eles. Inicialmente, são discutidas as aplicações da IA ao longo do processo forense e os benefícios relatados. Em seguida, analisam-se os

limites da confiabilidade dos resultados, a contribuição da explicabilidade, o papel do especialista humano e, por fim, as lacunas que permanecem em aberto.

3.1 Aplicações da IA ao longo do processo forense

A fim de analisar diferentes aplicações da inteligência artificial no ramo de computação forense, é imperativo considerar as etapas que compõem o processo de investigação forense. Nesse sentido, não há um modelo generalizado que funcione para todos os casos, mas há um, chamado DFRWS (Digital Forensics Research Workshop), que pode ser aplicado em vários casos que envolvem investigações na área de forense digital. Nesse modelo, há seis fases: identificar, preservar, coletar, examinar, analisar e apresentar (Tanner e Dampier, 2009 apud [Artigo 1]). Para organizar e comparar as aplicações de IA identificadas nos estudos selecionados, as fases serão agrupadas em três blocos: aquisição e triagem, exame e análise, e apresentação ou relatório.

Garfinkel (2010) afirma que, na aquisição, a IA analisa conjuntos de dados complexos que seria impossível para um humano com especialidade na área forense analisar manualmente [Artigo 2]. Para a triagem de casos, Du et al. (2020) investigaram a possibilidade de utilizar casos de forense digital previamente investigados para auxiliar na investigação de novos casos, utilizando sistemas de inteligência artificial automatizados. Ao avaliar o processo automatizado com arquivos de três diferentes cenários, a fim de identificar arquivos similares e desconhecidos, o estudo conseguiu concluir seu objetivo [Artigo 2]. Nesse âmbito, ao examinar três fornecedores-chave de software da área de computação forense e as ferramentas de IA oferecidas, evidencia-se o quão longe a indústria ainda deve ir [Artigo 3]. Nesse contexto, a Magnet Forensics, fabricante da ferramenta de exame forense Magnet Axiom, implementou *machine learning* no módulo Magnet.AI, que classifica *chats* de usuários e imagens de evidências em classificações específicas, fazendo a triagem de dados [Artigo 3].

Al Fahdi et al. (2016) afirmam que softwares impulsionados por IA estão sendo usados para facilitar a examinação e a análise forense. Assim, é permitido que profissionais forenses examinem e analisem evidências digitais em diversos crimes computacionais, incluindo, mas não se limitando a, *malware*, *spyware*, *hacking*, roubo de dados e roubo de identidade [Artigo 1]. Nesse contexto, segundo Hemdan e Manjaiah (2017), IA e ML podem ajudar em análises forenses ao identificar anomalias em tráfego de redes, detectar *malware*, classificar arquivos com base no seu conteúdo e reconhecer objetos e pessoas em imagens e vídeos [Artigo 2]. No artigo "A comprehensive analysis of the role of artificial intelligence and machine learning in modern digital forensics and incident response", os autores citam Toraskar et al. (2019), que apresentaram quatro cenários de crimes cibernéticos para avaliar a dependência de *machine learning* em análises forenses. Esses cenários incluíam: roubo de dados, fraude corporativa, *hacking* e fraude de documentos. Em cada um desses casos, o mapa auto-organizado (*Self-Organizing Map* – SOM) é usado para agrupar dados notáveis, demonstrando sua eficácia em diferentes contextos [Artigo 2].

Os autores do artigo "Explainable Artificial Intelligence for Digital Forensics" reconhecem que a integração de dados de forma efetiva e eficiente é uma função essencial da área de forense digital. Com base em um relatório de órgãos policiais do Reino Unido (Forensic Capability Network et al., 2020 apud [Artigo 3]), eles afirmam que implementar uma tecnologia melhorada para pesquisa e revisão, incluindo técnicas de IA e ML, deve ser priorizado, e reconhecem a IA como área-chave em que os agentes da lei poderiam colaborar com a indústria e com a área acadêmica. A Figura 1, feita pelos autores do artigo, aponta justamente o fluxo de como o processo de análise e de apresentação/relatório ocorre atualmente nas ferramentas de IA dos fornecedores. A fase de apresentação, justamente a que leva a evidência ao tribunal, aparece quase só neste artigo selecionado.

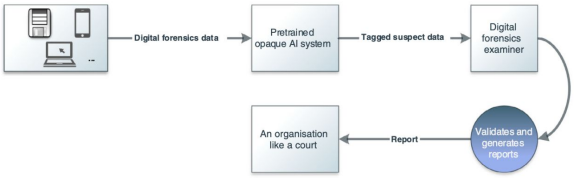


FIGURE 1 AI in DF. State-of-the-art in vendor implementations

Figura 1: IA na forense digital: estado da arte nas implementações dos fornecedores. Fonte: Hall, Sakzad e Choo [Artigo 3].

3.2 Benefícios: tempo, volume de dados e custo

No artigo "The Impact of Automation and Artificial Intelligence on Digital Forensics", os autores afirmam que o uso de IA na área de computação forense permite que os especialistas forenses encontrem respostas para perguntas significantes em menos tempo e com menos custo [Artigo 1]. Segundo os autores do artigo, o uso de IA tem três benefícios destacados, sendo estes: 1) otimizar o tempo dos investigadores, permitindo que eles identifiquem, rastreiem e solucionem casos de forma mais eficiente e, paralelamente, minimizem efeitos colaterais; 2) ajudar os investigadores a rastrear e conter crimes futuros ou incidentes que envolvem técnicas parecidas entre si; 3) baratear os custos: a implementação de sistemas de IA ajuda a poupar muito dinheiro, ao reduzir recursos humanos e a carga horária, o que pode então ser reinvestido para desenvolver melhores infraestruturas tecnológicas que requerem mínima intervenção humana [Artigo 1]. O artigo trouxe alguns dados para sustentar essas reivindicações: de acordo com Vestige Limited (2018), o custo para contratar especialistas da área forense é substancial. Pesquisas determinaram que uma análise de imagem feita por um especialista forense custa entre 5.000 e 15.000 dólares, enquanto análises e processamento de imagens mais complexas e de vídeos podem exceder 100.000 dólares (Vestige Limited, 2018 apud [Artigo 1]).

Nesse contexto, o artigo "A comprehensive analysis of the role of artificial intelligence and machine learning in modern digital forensics and incident response" cita Hasan et al. (2011), que propuseram um modelo computacional que utiliza IA a fim de acelerar investigações forenses e reduzir o tempo e os recursos necessários aos investigadores criminais. Os autores apontam como ponto positivo

do modelo a habilidade de analisar de maneira eficiente a evidência da cena do crime e gerar conclusões acuradas, em menos tempo [Artigo 2].

O artigo "Explainable Artificial Intelligence for Digital Forensics" também converge nesse ponto, ao mencionar que os tempos de espera e de processamento dos serviços de computação forense aumentam à medida que aparelhos e ferramentas aumentam em sofisticação [Artigo 3]. Os autores citam Quick e Choo (2014), que destacaram um potencial modelo para reduzir dados, chamado Digital Forensic Data Reduction Framework, para abordar os tempos de espera e de processamento através do uso de captura predefinida de dados, baseada em características derivadas de *data mining* [Artigo 3].

3.3 Limites da confiabilidade: dados, validação e generalização

A implementação da inteligência artificial na computação forense requer cuidado no que diz respeito à validação do dado sendo analisado e processado. No entanto, determinar a validade do dado apresenta um desafio significativo, porque poucos pesquisadores compartilharam métodos eficazes de validação [Artigo 2]. De acordo com Zhang et al. (2018), a disponibilidade e a qualidade do dado também podem representar desafios para treinar e avaliar modelos de *machine learning* na computação forense, pois dados incompletos, caóticos ou parciais podem apresentar dificuldades [Artigo 2]. Nesse contexto, dados de treinamento estão sujeitos a controles legais, e as justificativas da XAI podem herdar viés dos dados ou das decisões dos desenvolvedores [Artigo 3].

Nesse âmbito, os estudos apresentam resultados de acurácia bastante elevados para modelos de IA aplicados à computação forense. Segundo Kanimozhi e Jacob (2019), sistemas de detecção de intrusão em redes baseados em redes neurais artificiais conseguem identificar tráfego intrusivo com 99,97% de acurácia [Artigo 1]. De forma semelhante, Mosli et al. (2016), ao desenvolver um modelo para automatizar a detecção de *malware* a partir de imagens de memória, obtiveram taxas de acurácia entre 85,7% e 96%, enquanto o sistema de Kanzig et al. (2019), treinado com dados dos exercícios Locked Shields, alcançou 99% de precisão e mais de 90% de *recall* [Artigo 2]. No entanto, esses números precisam ser analisados junto com a dificuldade de generalização dos modelos. Devido à grande variedade de dispositivos, sistemas operacionais e formatos de arquivos encontrados em investigações, modelos de *machine learning* podem ter dificuldade em generalizar para essas diferentes categorias de dados [Artigo 2]. O próprio modelo de Kanzig et al. (2019) apresenta uma possível inflexibilidade para se adaptar a ambientes de rede diferentes ou a novos tipos de comunicação que não estavam presentes nos dados de treinamento, e o estudo de Mittal et al. (2021) utilizou conjuntos de dados com problemas de dependência, o que dificultou a generalização do classificador para outros tipos de arquivos [Artigo 2]. Dessa forma, percebe-se que uma acurácia alta medida em um ambiente controlado não garante, necessariamente, o mesmo desempenho em casos reais.

Nesse contexto, a questão dos falsos positivos e falsos negativos também aparece como um ponto importante para a confiabilidade dos resultados. Tian et al. (2014) demonstraram que seu modelo de fusão de evidências digitais obteve uma taxa maior de verdadeiros positivos e menor de falsos positivos em comparação com os métodos de forense de rede considerados padrão na época [Artigo 1]. Por outro lado, o artigo "A comprehensive analysis of the role of artificial intelligence and machine learning in modern digital forensics and incident response" mostra que esse problema ainda está longe de ser resolvido: ferramentas forenses tradicionais apresentam a inabilidade de distinguir falsos negativos de verdadeiros positivos, e, segundo Eykholt et al. (2018), o uso de dados experimentais fabricados, como no estudo de Du et al. (2020), pode levar a mais falsos positivos e falsos negativos do que o uso de dados de casos reais [Artigo 2]. Além disso, os autores apontam que o modelo de *deep learning* de Al Neaimi et al. (2020), apesar das altas taxas de acurácia, se beneficiaria de uma discussão mais cuidadosa sobre suas limitações e sobre o potencial de falsos positivos e negativos para avaliar sua aplicabilidade no mundo real [Artigo 2].

Ainda no que diz respeito à confiabilidade, os artigos "A comprehensive analysis of the role of artificial intelligence and machine learning in modern digital forensics and incident response" e "Explainable Artificial Intelligence for Digital Forensics" convergem ao apontar o risco de ataques adversariais e de manipulação dos modelos. De acordo com Biggio et al. (2013), em ataques adversariais o atacante gera entradas com a intenção de confundir modelos de *machine learning*, o que é especialmente preocupante na computação forense, onde as implicações de resultados imprecisos ou não confiáveis podem ser graves [Artigo 2]. Nesse sentido, Eykholt et al. (2018) apresentaram o método RP2, capaz de gerar perturbações que enganam classificadores em condições físicas reais, e o próprio estudo aponta investigações de forense digital como um dos domínios onde essa questão deveria ser explorada futuramente [Artigo 2]. Além disso, segundo Trifonov et al. (2019), o modelo proposto por Hasan et al. (2011) não considera o risco de interferência de *hackers* e de softwares de terceiros [Artigo 2]. O artigo "Explainable Artificial Intelligence for Digital Forensics" levanta a mesma preocupação ao afirmar que, com a introdução de IA na forense digital, deve-se considerar o risco de modelos treinados com dados comprometidos ou enviesados, questionando como é possível saber se os modelos usados nas investigações podem ser confiáveis, além da dificuldade de garantir que evidências apresentadas em tribunal não sejam *deepfakes* [Artigo 3].

Por fim, os três estudos permitem observar que muitos dos modelos propostos ainda carecem de validação experimental. Segundo a revisão sobre os impactos da automação e da IA na forense digital, a abordagem baseada em metadados de Mohammed, Clarke e Li (2016) para automatizar o processamento de *big data* em investigações forenses parece ser eficaz, mas não há estudos experimentais que comprovem sua efetividade e usabilidade [Artigo 1]. Da mesma forma, o modelo de resposta a incidentes de Hasan et al. (2011) não apresentou nenhuma demonstração prática ou experimental, sendo seu desenvolvimento e teste deixados como trabalhos futuros [Artigo 1]. Esse mesmo modelo também é criticado na revisão sobre IA e ML em forense digital e resposta a incidentes, que, com base em Nila et al. (2020), aponta que o trabalho necessário para coletar dados suficientes para treinar o modelo foi descrito de forma inadequada, e que os dados coletados de agências policiais do Reino Unido podem estar vulneráveis a *malware*, anomalias e injeções de código malicioso [Artigo 2]. Já o modelo XAI *for Investigative Support*, proposto no estudo sobre XAI na forense digital, é teórico, e o

caso utilizado para ilustrá-lo é fictício, embora compartilhe semelhanças com casos reais [Artigo 3]. Nesse cenário, a validação dos resultados deixa de ser apenas uma questão técnica, pois, segundo a revisão sobre IA e ML em forense digital e resposta a incidentes, a admissibilidade de evidências coletadas por IA em tribunais depende de que sua confiabilidade seja estabelecida, o que pode ser alcançado por meio de procedimentos e diretrizes padronizados [Artigo 2].

3.4 Da caixa-preta à explicabilidade: a contribuição da XAI

Doran et al. (2017) destacam quatro categorias de XAI, baseadas na interpretabilidade presente em um modelo particular de XAI, que são: sistemas opacos (caixa-preta), sistemas interpretáveis, sistemas compreensíveis e sistemas genuinamente explicáveis, como apresentado na Figura 2 [Artigo 3]. Os sistemas opacos introduzem o problema da caixa-preta: os usuários não conseguem entender como o modelo chegou à decisão, uma vez que o sistema apenas fornece dados de saída [Artigo 3]. Nesse contexto, a revisão sobre IA e ML em forense digital e resposta a incidentes aponta que a opacidade das redes neurais profundas, como a apresentada por Krizhevsky et al. (2017), é um desafio de interpretabilidade, e que é difícil saber se as saídas estão corretas (Lipton, 2018) [Artigo 2].

Nesse cenário, as ferramentas atuais de computação forense são opacas (caixa-preta): marcam o arquivo, mas não fornecem justificativa, sendo o examinador quem precisa validar a informação [Artigo 3]. Para os autores do artigo, a área precisa de IA genuinamente explicável, que faz uso de bases de conhecimento que contextualizam os dados analisados no sistema e, portanto, fornecem um mecanismo pelo qual achados individuais podem ser desconstruídos, de formas variadas, para fornecer uma justificativa para a interpretação do modelo que segue logicamente dos dados de entrada [Artigo 3].

Nesse sentido, a explicabilidade depende da fase da forense digital. Na triagem, por exemplo, a XAI tem uso limitado e a transparência é opcional. No tribunal, no entanto, a decisão precisa ser explicável: segundo o estudo sobre XAI na forense digital, do ponto de vista dos agentes da lei, a XAI pode ter uso limitado na primeira etapa do processo investigativo, uma vez que a maior parte das análises forenses é realizada depois que o suspeito já foi preso e quando já se acredita na existência de evidências contra ele [Artigo 3]. Nesse momento da investigação, a transparência do sistema é considerada opcional, pois o investigador e o analista forense não estão utilizando o resultado do modelo como base para levar acusações ao tribunal, podendo a XAI funcionar de forma semelhante às ferramentas atuais, que dependem da validação do examinador [Artigo 3]. No entanto, quando a evidência chega ao tribunal, os autores argumentam que não basta que a IA seja transparente: sua tomada de decisão também precisa ser precisa, compreensível para o tribunal e passível de ser explicada durante o processo judicial, considerando que as informações técnicas precisam ser comunicadas a pessoas com diferentes níveis de conhecimento técnico [Artigo 3]. Assim, a integração da XAI mudaria a forma como a evidência digital é apresentada em procedimentos legais, podendo ser necessária a explicação do resultado e da metodologia do modelo, ou uma documentação detalhada [Artigo 3]. Retomando as fases apresentadas na Seção 3.1, percebe-se que a exigência de explicabilidade cresce à medida que a evidência se aproxima da fase de apresentação, justamente a etapa que leva a evidência ao tribunal.

Nesse contexto, tanto a revisão sobre IA e ML em forense digital e resposta a incidentes quanto o estudo sobre XAI na forense digital concordam que a confiabilidade e a justificação dos resultados são condições para que a evidência produzida com IA seja aceita em tribunal, mas divergem no caminho apontado para isso. Segundo a revisão sobre IA e ML em forense digital e resposta a incidentes, a admissibilidade de evidências coletadas por IA depende de que sua confiabilidade seja estabelecida, o que pode ser alcançado por meio de procedimentos e diretrizes padronizados, e é essencial desenvolver ferramentas que garantam processos éticos e legalmente admissíveis [Artigo 2]. Já o estudo sobre XAI na forense digital propõe a explicabilidade como caminho, ao afirmar que as implementações atuais de IA na área são opacas, precisam ser validadas por um examinador forense e dificilmente seriam explicáveis em um tribunal [Artigo 3]. Contudo, os próprios autores admitem que a admissibilidade no tribunal de análises feitas por uma IA genuinamente explicável ainda não pode ser determinada, pois isso exigiria uma análise da legislação existente relacionada a evidências [Artigo 3]. Além disso, o estudo aponta uma tensão entre o interesse das empresas em proteger suas ferramentas de IA proprietárias, que funcionam como caixa-preta, e a forte exigência de transparência do setor público [Artigo 3]. Segundo os autores, se o resultado de um modelo puder ser validado por meio de justificativas logicamente consistentes geradas pelo próprio sistema, a necessidade de transparência do modelo é reduzida, mas não eliminada, o que poderia permitir que os fornecedores protegessem suas tecnologias [Artigo 3]. Vale destacar, ainda, que a revisão sobre os impactos da automação e da IA na forense digital não aborda a questão da explicabilidade, o que indica que o tema ganhou espaço de forma mais recente na discussão sobre o uso de IA na computação forense.

3.5 O papel do especialista humano

Apesar dos benefícios apresentados, os estudos analisados não sustentam a ideia de que a IA possa substituir o especialista humano na computação forense. Segundo James e Gladyshev (2013), a tecnologia baseada em IA pode servir somente como uma ferramenta que facilita as investigações, sendo ainda necessária a checagem humana de investigadores especialistas, uma vez que as ferramentas de IA ainda estão em desenvolvimento e podem nem sempre fornecer informações precisas, completas ou robustas [Artigo 1]. Nesse sentido, Spencer (2018) afirma que a eficiência e a precisão das investigações podem ser ampliadas ao combinar sistemas digitais com investigadores humanos qualificados, e chega a considerar que a automação completa da forense digital é potencialmente impossível [Artigo 1]. O estudo sobre XAI na forense digital converge nesse ponto, ao afirmar que cada uma das abordagens com IA na área busca reduzir a necessidade de interação humana com o dado, e não eliminá-la, sendo difícil imaginar um cenário em que o elemento humano seja completamente removido do processo [Artigo 3]. Já a revisão sobre IA e ML em forense digital e resposta a incidentes

TABLE 1 Categorization of XAI models based on the level of interpretability and their brief description

Interpretability	Feature
Opaque (black-box)	No insight into algorithm, provides only output data
Interpretable	Formulas/methodologies known, transparent in nature, provides only output data
Comprehensible	No insight into algorithm, provides textual/feature based references, justify decision making
Truly explainable	Contextualizes input data, justify output recognizable to a human, User-centric by design

Figura 2: Categorização de modelos de XAI com base no nível de interpretabilidade. Fonte: Hall, Sakzad e Choo [Artigo 3], com base em Doran et al. (2017).

não trata dessa questão de forma explícita, destacando principalmente a redução do número de casos que precisam ser analisados manualmente [Artigo 2].

Nesse contexto, é possível observar uma tensão dentro da própria revisão sobre os impactos da automação e da IA na forense digital. Por um lado, os autores afirmam que investigações com IA apresentam uma redução notável do erro humano [Artigo 1]. Por outro, com base em James e Gladyshev (2013), o mesmo estudo aponta que a precisão dessas ferramentas depende da habilidade do investigador, e que profissionais inexperientes que confiam totalmente nos sistemas automatizados aumentam a probabilidade de investigações fracassadas [Artigo 1]. Dessa forma, a IA pode reduzir certos tipos de erro, mas cria uma nova dependência: a capacidade humana de validar os resultados produzidos.

Assim, o perfil do especialista também tende a mudar. A revisão sobre os impactos da automação e da IA na forense digital aponta a necessidade de treinamento e de desenvolvimento de habilidades dos investigadores, além da falta de certificações e de órgãos reguladores que garantam que apenas investigadores certificados atuem no mercado [Artigo 1]. Já o estudo sobre XAI na forense digital afirma que os examinadores precisarão entender não apenas os sistemas que estão examinando, mas também os sistemas de XAI que fazem previsões por eles, e que recrutar profissionais com esse conhecimento é difícil, já que a indústria compete pelo mesmo perfil, geralmente oferecendo salários melhores [Artigo 3]. Além disso, dois dos estudos destacam o papel da IA na proteção do próprio examinador: Du et al. (2020) apontam que processos automatizados podem evitar efeitos psicológicos negativos da análise de evidências [Artigo 2], e o estudo sobre XAI na forense digital sugere que a XAI poderia classificar imagens de abuso infantil sem que o examinador precise visualizá-las [Artigo 3]. Nesse cenário, o especialista deixa de ser apenas um operador de ferramentas e passa a atuar como validador e intérprete dos resultados.

3.6 Lacunas e questões em aberto

A partir da análise dos três estudos, algumas questões permanecem em aberto. Do ponto de vista técnico, a generalização dos modelos para diferentes dispositivos, ambientes e tipos de dados ainda é um desafio, e a revisão sobre IA e ML em forense digital e resposta a incidentes aponta a necessidade de dados mais diversos, inclusive de diferentes regiões, e de estratégias baseadas em IA para áreas como a investigação de infecções por *malware* e a forense do registro do Windows [Artigo 2]. O estudo sobre XAI na forense digital também indica o desenvolvimento e a análise de *frameworks* para testar a robustez de sistemas de XAI como uma direção promissora de pesquisa [Artigo 3].

Do ponto de vista metodológico, uma lacuna que aparece nos três estudos é a falta de validação em casos reais: modelos sem demonstração experimental [Artigo 1], estudos baseados em dados fabricados [Artigo 2] e uma proposta teórica ilustrada por um caso fictício [Artigo 3]. Por fim, do ponto de vista jurídico e institucional, a admissibilidade de análises feitas com XAI ainda não pode ser determinada [Artigo 3], e os estudos apontam a ausência de padronização, seja pela falta de órgãos de certificação [Artigo 1], pela necessidade de procedimentos padronizados para a admissibilidade das evidências [Artigo 2] ou pela ausência de procedimentos padronizados de relatório no laboratório descrito no caso de estudo [Artigo 3].

4 Conclusões

Este artigo buscou analisar, por meio de uma pesquisa bibliográfica exploratória, como a inteligência artificial vem sendo aplicada à computação forense e quais desafios precisam ser enfrentados para que seus resultados sejam confiáveis e compreensíveis. A partir da análise dos três estudos selecionados, observou-se que a IA vem sendo aplicada principalmente nas fases de triagem, exame e análise do processo forense, em tarefas como detecção de *malware* e de intrusões, classificação de arquivos, agrupamento de dados e identificação de padrões em grandes volumes de evidências. Os estudos convergem ao apontar benefícios como a redução do tempo de investigação e a capacidade de lidar com grandes volumes de dados, enquanto a redução de custos aparece de forma mais destacada na revisão sobre os impactos da automação e da IA na forense digital.

No entanto, a análise mostrou que a eficiência não é suficiente para garantir a utilização dessas técnicas em investigações. A confiabilidade dos resultados ainda é limitada pela qualidade e pelo viés dos dados, pela dificuldade de generalização dos modelos, pelos falsos positivos e negativos, pelo risco de ataques adversariais e pela falta de validação em casos reais. Nesse contexto, a explicabilidade surge como uma das propostas para tornar os resultados compreensíveis, especialmente na fase de apresentação da evidência em tribunal, embora sua admissibilidade ainda não possa ser determinada. Além disso, os estudos indicam que o especialista humano continua sendo necessário, agora com o papel de validar e interpretar os resultados produzidos pela IA.

Dessa forma, conclui-se que a IA tem um potencial significativo para apoiar a computação forense, mas que seus resultados só poderão ser considerados confiáveis e compreensíveis se forem enfrentados desafios relacionados à validação, à padronização, à explicabilidade e à formação dos profissionais da área.

Referências

ANTHROPIC. **Claude** (Opus 5.5). [*S. l.*]: Anthropic, 2026. Disponível em: https://claude.ai. Acesso em: 29 set. 2026.

DUNSIN, Dipo; GHANEM, Mohamed C.; OUAZZANE, Karim; VASSILEV, Vassil. A comprehensive analysis of the role of artificial intelligence and machine learning in modern digital forensics and incident response. **Forensic Science International: Digital Investigation**, v. 48, 301675, 2024. DOI: 10.1016/j.fsidi.2023.301675.

HALL, Stuart W.; SAKZAD, Amin; CHOO, Kim-Kwang Raymond. Explainable artificial intelligence for digital forensics. **WIREs Forensic Science**, v. 4, n. 2, e1434, 2022. DOI: 10.1002/wfs2.1434.

JARRETT, Aaron; CHOO, Kim-Kwang Raymond. The impact of automation and artificial intelligence on digital forensics. **WIREs Forensic Science**, v. 3, n. 6, e1418, 2021. DOI: 10.1002/wfs2.1418.

Nota sobre o uso de inteligência artificial: durante a elaboração deste trabalho, foi utilizada a ferramenta de inteligência artificial Claude (ANTHROPIC, 2026) como apoio na correção gramatical do texto, na formatação do documento em LaTeX (ajuste de tabelas, inserção de figuras e criação dos *hyperlinks* para as referências) e na padronização das referências segundo a ABNT. A seleção dos estudos, as anotações, a análise e o conteúdo do artigo são de responsabilidade da autora.